

SPECYFIKACJA · BEZ WDROŻEŃ

Jak łapać deltę KRS: zmiany, zarządy, nazwy, nowe spółki

Od pytania „co jeśli zmieni się prezes?” do joba biuletynu MS, kolejek Core i tego, czego Open API nie powie. GUS range_scan zostaje bootstrapem — nie detektorem zmian.

Element	Stan
Pytanie źródłowe	Jak automatycznie wyłapać zmianę prezesa / nową spółkę, skoro dziś zaciągam GUS?
Werdykt	Silnik diff (fingerprint) jest gotowy. Napęd „kogo dziś odpytać” — nie. Pełny skan GUS tego nie załatwi.
Źródło delty	Open API MS: Biuletyn dzienny/godzinowy = lista KRS. Odpis aktualny = stan. Diff = co się zmieniło.
Gdzie kod	Job biuletynu + kolejka = polish-company-data-core. Diff/snapshot = istniejący capture Rejestr360/Core.
Świadomie nie	Re-scan 1,2 mln GUS; drugi detektor zmian; pchanie biuletynu przez monitoring-refresh (3/cykl).
Ten dokument	Read-only. Zero commitów, migracji, crona na produkcji.

0. Jedna teza

Biuletyn MS mówi KTO się ruszył. Odpis + SHA-256 mówią CO (prezes, nazwa, adres, kapitał...). GUS BIR przy pierwszym zaciągnięciu daje tożsamość — prezesa tam nie ma. Monitoring = ponowne zdjęcie tego samego KRS i porównanie, nie „zaciągnąłem wszystko jeszcze raz”.

1. Dwa różne problemy

Mieszanie ich w jednym skanie GUS to najdroższy błąd. Nowa spółka to insert tożsamości + baseline bez alertu. Zmiana prezesa to diff stanu już znanej spółki. Źródła i kontrakty eventów są inne.

Pytanie	Źródło prawdy	Czy jest dziś
Pojawił się nowy KRS	Biuletyn MS (KRS, którego nie ma w Core) i/lub ogon BIR przy bootstrapie	Tylko range_scan. Brak pętli „co przybyło wczoraj”.
Prezes / reprezentacja / prokura	Odpis aktualny KRS dział 2 (+ CRBR jako osobna oś)	Diff GOTOWY. Odpytywanie tylko watchlista + wejście na profil.
Nazwa spółki	Odpis dział 1 + pl_companies.legal_name	Diff NIE — legalName nie jest w snapshotcie (luka, §5).
Adres / PKD / kapitał / działy 4-6	Odpis + Core enrichment	Diff GOTOWY, o ile ktoś zrobił capture.

2. Co już stoi (nie budować drugi raz)

Rejestr360 ma Persistent Monitoring Core v1. To jest właściwa semantyka. Nowe joby tylko dostarczają listę KRS do tej funkcji.

2.1 Przepływ, który już istnieje

- Źródła (odpis KRS, CRBR, fakty Core) → znormalizowany stan semantyczny bez fetchedAt.

- Fingerprint SHA-256 całego stanu + osobne hashe plasterków: Core / KRS / CRBR / relacje / filings / sygnały 4-6.
- Pierwsza obserwacja = baseline, zero alertu. Ten sam hash → tylko last_seen_at. Nowy hash → diff.
- Klasy v1: status_change, registry_profile_change, activity_change, representation_change, beneficial_owners_change, capital_change, relationship_change, financial_filing, registry_signal, crbr_event.
- Materiality jawna: critical / material / informational — nigdy score.
- Daty: effective_date tylko gdy źródło ją daje; inaczej okno window_start → window_end (nie wymyślamy daty wpisu).
- Tabele Core: pl_source_snapshots, pl_detected_changes (RLS deny-by-default, service-role tylko serwer).
- Product: ri_monitor_subjects (1 subject / KRS), fan-out do ri_alert_events, unique (watchlist_id, core_change_id).
- Scheduler produktowy: pg_cron → Edge monitoring-refresh, max 3 spółki naraz, lease 5 min, cadence 60 min.

2.2 Gdzie jest dziura

Capture odpala się tylko gdy ktoś wejdzie na profil (after(capture...)) albo spółka jest na watchliście. Nieoglądana spółka = nie wiesz, że prezes odszedł. Cron 3 podmioty/cykl przy 1,2 mln ≈ lata na pełny obrót. To celowo warstwa PRO, nie narodowy radar. GUS range_scan też nie naprawi: BIR nie zwraca składu zarządu.

3. Źródło delty — Open API MS

Dokumentacja PRS: oprócz odpisu jest usługa „historia zmian we wskazanym dniu”. Bez klucza, ten sam host co odpis, który już wołasz w krs.ts.

Endpoint	Parametr	Odpowiedź	Rola
GET /api/Krs/Biuletyn/{dzien}	dzien = YYYY-MM-DD, ≥ 2021-12-08	tablica stringów = numery KRS	dzienna lista „kogo ruszyć”
GET /api/Krs/BiuletynGodzinowy/{dzien}	godzinaOd, godzinaDo	to samo, węższe okno	niższy lag 8-18
GET /api/krs/OdpisAktualny/{krs}	rejestr=PJS, format=json	pełny stan (parser już jest)	CO się zmieniło

Biuletyn nie mówi, czy to prezes, nazwa czy adres — tylko że ten KRS tego dnia miał wpis. Dlatego po liście zawsze idzie odpis → istniejący fingerprint. Skala: typowy dzień to tysiące KRS, nie milion. Przy 1,5 odpisach/s ≈ 30-60 min na dzień. To jest wykonalne. Re-scan 1,2 mln odpisu — nie.

Base: <https://api-krs.ms.gov.pl> — ten sam co OdpisAktualny w src/lib/data/krs.ts (revalidate 21600 jest OK dla strony; delta musi no-store).

4. Architektura docelowa

[A] krs_bulletin_ingest (Core, Python, lekki) → pl_krs_delta_days + pl_krs_delta_queue

[B] krs_delta_apply (Core, Python, ciężki) → upsert tożsamości + odpis + capture

[C] Product watchlista (już jest) → SLA 60 min dla obserwowanych + fan-out inbox

Silnik	Cel	Częstość	Skala
Delta narodowa (nowe)	wszystkie KRS z biuletynu	dzień + opcjonalnie godziny	~tysiące/dzień
Watchlista (istnieje)	spółki obserwowane / PRO	60 min	limity planu (5 / 100 / ...)

Oba silniki kończą na captureCompanyMonitoringSnapshot. Zero drugiego detektora. Biuletynu nie pchać przez monitoring-refresh — ten jest celowo wąski, żeby nie mnożyć ruchu do MS na 100 watcherów tego samego Orlenu (1 subject / KRS — to zostaje).

4.1 Granica baz

Core (narodowe, neutralne)	Product (kto ogląda)
pl_companies, aliasy, odpis cache jeśli będzie	ri_watchlists, ri_monitor_subjects
pl_krs_delta_days, pl_krs_delta_queue	ri_alert_events, ri_monitor_runs
pl_source_snapshots, pl_detected_changes	e-mail / preferencje / entitlements
Job A/B, budżet Open API	Cron watchlisty, Decision Inbox

Narodowy firehose zmian nie leci do FREE. Inbox dostaje event tylko jeśli KRS jest na czyjejs watchliście (albo później: osobny feed „nowe spółki” jako produkt).

5. Luka modelu: nazwa spółki

diffMonitoringStates już porównuje boardMembers, proxies, representationRule — zmiana prezesa/reprezentacji jest w kontrakcie. MonitoringStateV1.core ma status, formę, adres, PKD — nie ma legalName. Parser odpisu w krs.ts też nie wyklada nazwy z działu 1 do KrsSnapshot. Bez tej poprawki delta narodowa złapie zarząd, a nie zmianę firmy ze „X sp. z o.o.” na „X 2 sp. z o.o.”.

Dodatek do kontraktu v1	Po co
core.legalName (z pl_companies)	stan, który produkt już pokazuje w search
krsState.legalName (z odpisu dział 1)	źródło sądowe, niezależne od GUS
kind = name_change, materiality = material	osobny event, nie chować w „adres/forma”
stara nazwa → pl_company_aliases	search po poprzedniej nazwie nadal działa

To jedyna zmiana kontraktu monitoringu przed jobem delty. Reszta to nowy worker i tabele kolejki. Nie ruszamy range_scan.

6. Tabele Core

6.1 pl_krs_delta_days

day date PK · ingested_at · krs_count · status (pending | ok | partial | failed) · source (biuletyn_daily | biuletyn_hourly). Pusta tablica / weekend = status ok, count 0 — nie retry w kółko.

6.2 pl_krs_delta_queue

id · krs · bulletin_day · hour_from/to nullable · reason (bulletin | new_entity | retry) · status (queued | leased | done | failed | skipped) · lease_until · attempts · last_error. Unique (krs, bulletin_day): ten sam KRS trzy razy w biuletynie = jeden odpis. Kolejka nie trzyma snapshotu.

RLS jak reszta Core: włączony, brak polityk anon/authenticated, zapis tylko service-role workera.

7. Job A — krs_bulletin_ingest (lekki)

Osobny stream_key. Nie woła GUS. Nie woła odpisu. Nie blokuje range_scan.

1. Kursor: ostatni dzień ze statusem ok + 1. Start operacyjny: max(wczoraj, pierwszy brakujący). Catch-up: pętla braków, nie skok do „dziś”.
2. GET /api/Krs/Biuletyn/{day} — timeout, retry 429/5xx z backoffiem, log statusu.
3. 404 / pusta tablica → dzień ok, count 0 (święto, weekend, lag MS).
4. Normalizacja KRS do 10 cyfr. Odrzuć 0000000000 i śmieci.
5. Upsert kolejki reason=bulletin. Dzień → ok + krs_count.

7.1 Harmonogram (Europe/Warsaw)

Kiedy	Co	Dlaczego
06:30	Biuletyn D-1	Sądy dociągają wieczorem; D-0 o świcie bywa niekompletny.
16:00	Biuletyn D-0	To, co wpadło w dzień roboczy.

Kiedy	Co	Dlaczego
Opcja faza 2	BiuletynGodzinowy 8-18	Niższy lag na reprezentację; te same unique w kolejce.

8. Job B — krs_delta_apply (ciężki)

Osobny stream_key i osobny budżet req/h od BIR. Claim FOR UPDATE SKIP LOCKED, lease 5 min (jak watchlista). Limit np. 1,5 rps, burst 5. Capture nie przez publiczny /api/monitoring-health (P0). Albo wewnętrzny sekret BFF, albo bezpośredni zapis Core service-role z workera — preferowane: jeden kod persist, zero publicznej powierzchni zapisu.

#	Krok	Reguła
1	Odpis P, przy 404 S	Ten sam parser co getKrsSnapshot. Delta = cache: no-store (nie revalidate 6h ze strony).
2	Tożsamość	Brak w pl_companies → insert warstwy 1 z odpisu, reason logicznie new_entity. Jest → update legal_name, adres, krs_last_change_date = bulletin_day, last_verified_at. Stara nazwa → alias.
3	CRBR	Tylko gdy jest NIP i budżet. Inaczej odpis-only. Stabilizer już niesie stary plasterek CRBR — brak źródła ≠ wykreślenie beneficjenta.
4	Capture	Zbuduj candidate → persist. Nowa spółka = baseline, 0 alertów „prezes”. Znana + inny hash → pl_detected_changes.
5	Kolejka	done. 429 → queued + backoff. 3 fail → failed + alert ops. Timeout/5xx odpisu: nie zapisuj „usunięto zarząd”.

Nigdy nie materializuj usunięcia prezesa, nazwy ani CRBR, gdy odpis/CRBR zwrócił błąd. Brak obserwacji to nie stan „pusto”. To już jest w monitoringu-hardening — job B musi z tego korzystać, nie omijać.

9. Trzy przypadki — co system robi

Zdarzenie	Ścieżka	Event
Zmiana prezesa / prokury / sposobu reprezentacji	KRS w biuletynie lub na watchliście → odpis dział 2 ≠ krsState.board/proxies/rule	representation_change (material) — już w diff
Zmiana nazwy	Po §5: odpis dział 1 vs legalName → alias starej nazwy	name_change (material) — do dodania
Nowa spółka	KRS z biuletynu ≠ Core → insert + baseline	new_entity w feedzie Core; NIE representation_change; NIE inbox FREE
Adres / kapitał / PKD / działy 4-6	Odpis vs poprzedni snapshot	istniejące kindi (profile, capital, activity, registry_signal)
Watchlista PRO, zmiana w ciągu godziny	Istniejący cron, bez czekania na biuletyn D+1	ten sam pl_detected_changes, szybszy napęd

10. Ograniczenie Open API — nie wolno obiecać w PRO

Otwarte API anonimizuje osoby. Parser już podstawia „Dane osoby zanonimizowane w API KRS”. Jeśli stary i nowy skład mają tę samą liczbę ról i oba maski, Kowalski → Nowak może być niewidoczny.

Widać na Open API	Nie widać (albo nie obiecuj)
Sposób reprezentacji (tekst klauzuli)	Wymiana osoby przy identycznej masce i liczbie miejsc
Liczba członków / role / zawieszenia	Historyczny nieanonimowy graf (moat rejestr.io)
Nazwa spółki, kapitał, adres, PKD	PESEL, pełne imię z odpisu bez Full API
Działy 4/6, wzmianki o sprawozdaniach	„Zawsze wykryjemy zmianę prezesa po nazwisku”
CRBR — inne źródło, inne imiona	Pełna tożsamość osoby bez decyzji MS o Full API

MSiG (powołanie/odwołanie) jako faza 2 — uzupełnienie ślepej plamy, nie blocker startu biuletynu. Metryka ops: % odpowiedzi z w pełni zamaskowanym składem — świadomość, nie KPI produktu na landing.

11. Czego nie robić

- Nie wrzucaj odpisu / CRBR / RDF do range_scan GUS (DATA_LAYERS.md — budżet godzinowy, chudsze pierwsze spółki).
- Nie odpytuj 1,2 mln odpisu co dobę — MS zetnie, a cron watchlisty nie jest do tego.
- Nie pisz drugiego detektora. Jedna funkcja persist. Joby tylko karmią listę KRS.
- Nie wołaj capture przez publiczny monitoring-health (zapis bez auth = P0 z audytu).
- Nie cache’uj odpisu 6h na ścieżce delty.
- Nie wlewaj narodowego firehose do inboxu FREE.
- Nie wyłączaj watchlisty godzinowej po starcie biuletynu — PRO ma SLA „do godziny”, biuletyn „do jutra rano”.
- Nie traktuj „zaciągnąłem GUS” jako monitoringu. To spis. Monitoring = drugie zdjęcie + porównanie.

12. Wdrożenie — fazy (nadal wymaga zgody)

Faza	Zakres	Gdzie	Definition of Done
0	legalName w snapshot + name_change w diff + alias	ulepszonyrejstrio monitoring-model + parser dział 1	fixture: zmiana nazwy → 1 event; zmiana board → representation_change
1	Tabele + job A (tylko kolejka)	Core Python	7 dni wstecz wciągnięte; dashboard krs/dzień; lag dni = 0/1
2	Job B: odpis + update Core + capture	Core → istniejący persist	1 dzień prod: kolejka → 0; sample 20 KRS ma nowy snapshot; 0 fałszywych usunięć przy 5xx
3	new_entity + aliasy nazw	Core	nowy KRS nie emituje representation_change; search znajduje starą nazwę
4	Product czyta te same detected_changes dla watchlist	prawie nic	inbox PRO widzi delty „swoich” KRS, nie cały kraj
5	E-mail na representation_change / name_change	Product + Resend	po fazie 2; zgoda w koncie

GUS range_scan jedzie równolegle jako bootstrap uniwersum. Po pełnym KRS nowe podmioty biorą się z biuletynu, nie z re-scanu 1,31 mln. Faza 0 może iść w produkcie niezależnie od workera — bez niej nazwy i tak zginą.

13. Quota, idempotencja, bezpieczeństwo

Temat	Zasada
Budżet MS	Osobny licznik req/h od BIR. 429 = spowolnij job B, nie job A.
Idempotencja	unique (krs, bulletin_day) + istniejący event_fingerprint na pl_detected_changes.
Współbieżność	Lease + SKIP LOCKED. 409 na snapshot → recovery jak w captureCompanyMonitoringSnapshot.
Auth zapisu	Żadnego publicznego GET z side-effect. Worker = service role Core albo sekret M2M na prywatny BFF.
PII	Nie logować pełnych snapshotów. Health tylko prefiks hasha / count (jak dziś).
Region	Worker tam, gdzie Core (eu-central-1) albo self-hosted runner z już opisanym GUS — drugi stream, ten sam host OK.

14. Metryki (jedna kartka ops)

KPI	Czerwone jeśli
lag: today – last_ok_day biuletynu	> 1 dzień roboczy
długość kolejki queued+leased, p95 apply	rośnie przez > 6 h
% representation_change / name_change / new_entity / no-op (ten sam hash)	100% no-op przy niezerowym biuletynie = martwy odpis/cache
% odpisów z zamaskowanym składem	informacyjnie; nie KPI marketingu

KPI	Czerwone jeśli
429 / 5xx MS	lawina; cięcie rps
fałszywe usunięcia przy awarii źródła	jakikolwiek incydent = rollback semantyki job B

15. Mapowanie na audyt i plan 14+30 dni

Delta KRS nie zastępuje 14-dniowego bootstrapu tożsamości. Najpierw uniwersum (żeby „nowy KRS” miał z czym się zderzyć i żeby search nie kłamał). Job A można odpalić wcześniej (tylko kolejka — tanie). Job B — gdy odpis+capture nie idzie przez dziurawy health i gdy search/trigram nie pali budżetu równolegle. Watchlista godzinowa + e-mail zostają klinem PRO niezależnie od tego, czy narodowa delta już zjada cały biuletyn.

Zależność	Kolejność
range_scan GUS (warstwa 1)	jedzie; nie czeka na deltę
Search trigram + demo OFF + health bez write	przed jakimkolwiek zwiększeniem ruchu / apply na prod
Faza 0 name_change	przed ogłoszeniem „łapiemy zmiany nazw”
Job A biuletyn	może start nawet przy 200k kart — kolejka poczeka
Job B apply	po P0 health; limit rps; najpierw 1 dzień canary
Reklama „monitoring zmian KRS”	dopiero gdy watchlista+mail działają; narodowa delta to backend, nie obietnica landingu

16. Następny krok (Twoja zgoda)

Nic z tego nie jest w repo, dopóki nie powiesz. Najmniejszy pierwszy commit (gdy odblokujesz): (1) legalName + name_change w modelu monitoringu + test fixture, (2) migracja pl_krs_delta_days / queue w Core, (3) job A tylko ingest biuletynu na staging. Job B i publiczny capture zostawiam na osobne „rób”. Range_scan i RLS nie ruszam bez osobnej komendy.

Koniec specyfikacji. Źródła: docs/MONITORING_CORE.md, WATCHLIST_ORCHESTRATOR.md, DATA_LAYERS.md; src/lib/data/monitoring-core.ts, monitoring-model.ts, krs.ts; Open API PRS Biuletyn/OdpisAktualny; audyty 23–24.08.2026.